BOOTCAMP TALENTO TECH
ANÁLISIS DE DATOS INTEGRADOR

AquaRisk Colombia: Sistema Inteligente de Análisis y Visualización Histórica del Índice de Riesgo de Calidad del Agua (IRCA) en Colombia, 2007–2024

EQUIPO DE INVESTIGACIÓN Y DESARROLLO

Erica Julieth Panqueva Méndez

Sandra Milena Villegas Serna

Carlos A. Cárdenas Hernández

Andrea Juliana González Cárdenas

Nivel Intermedio

Marzo 2026

DOCUMENTO CIENTÍFICO Y TÉCNICO

RESUMEN

El presente proyecto desarrolla una aplicación web interactiva utilizando Python y Streamlit para analizar la evolución histórica del Índice de Riesgo de la Calidad del Agua (IRCA) en Colombia desde el año 2007 hasta 2024, abarcando niveles departamentales y municipales. La aplicación permite a los usuarios explorar indicadores de riesgo geográficamente, comparar zonas urbanas y rurales, e identificar municipios críticos que requieren intervención inmediata en salud pública. El sistema integra visualización de datos, análisis exploratorio y modelos predictivos para apoyar la toma de decisiones basada en evidencia respecto a la inversión en infraestructura hídrica. El IRCA, regulado por el Decreto 1575 de 2007 y la Resolución 2115 de 2007, clasifica la calidad del agua basándose en parámetros físicos, químicos y microbiológicos, sirviendo como el principal indicador de riesgo sanitario en el sistema de abastecimiento de agua de Colombia.

PALABRAS CLAVE: IRCA, calidad del agua, análisis de datos, Streamlit, Python, riesgo sanitario, Colombia, visualización interactiva, análisis predictivo, infraestructura hídrica.

ABSTRACT

This project develops an interactive web application using Python and Streamlit to analyze the historical evolution of the Water Quality Risk Index (IRCA) in Colombia from 2007 to 2024, at departmental and municipal levels. The application allows users to explore risk indicators by geography, compare urban and rural zones, and identify critical municipalities requiring immediate public health intervention. The system integrates data visualization, exploratory analysis, and predictive models to support evidence-based decision-making in water infrastructure investment. The IRCA, regulated by Decree 1575 of 2007 and Resolution 2115 of 2007, classifies water quality based on physical, chemical, and microbiological parameters, and serves as the main indicator of sanitary risk in Colombia's water supply system.

KEYWORDS: IRCA, water quality, data analysis, Streamlit, Python, sanitary risk, Colombia, interactive visualization, predictive analytics, water infrastructure.

1. INTRODUCCIÓN

El acceso al agua potable es un derecho fundamental y un pilar esencial para la salud pública y el desarrollo sostenible. A pesar de que Colombia es una de las naciones con mayor riqueza hídrica del mundo, enfrenta desafíos significativos para garantizar el suministro de agua segura a toda su población, existiendo marcadas disparidades regionales y sectoriales. El Índice de Riesgo de la Calidad del Agua para Consumo Humano (IRCA) se ha establecido como la herramienta normativa clave para monitorear este recurso vital.

Sin embargo, la mera recolección de datos no es suficiente. La inmensa cantidad de registros históricos generados desde la implementación de la normativa requiere herramientas avanzadas de procesamiento y visualización para ser útiles en la formulación de políticas públicas. Este proyecto aborda la necesidad crítica de transformar datos tabulares históricos en información visual e interactiva, permitiendo un análisis profundo de la evolución de la calidad del agua en el país durante los últimos 17 años.

2. PLANTEAMIENTO DEL PROBLEMA

Actualmente, existe una barrera tecnológica en el acceso y comprensión de los datos de calidad del agua. La información histórica del IRCA suele encontrarse dispersa o en formatos que dificultan su análisis integral. Esta carencia de herramientas interactivas genera los siguientes problemas específicos:

- **Dificultad en la identificación de riesgos:** No es sencillo detectar rápidamente qué municipios han mantenido niveles de agua "inviable sanitariamente" de manera crónica.
- **Riesgo para la salud pública:** La falta de alertas tempranas basadas en datos históricos impide prevenir brotes de enfermedades en comunidades vulnerables.
- **Invisibilidad de brechas:** Las diferencias de calidad entre zonas urbanas y rurales no están suficientemente documentadas de manera visual, lo que dificulta la asignación equitativa de recursos.
- **Limitaciones en la gestión:** Los prestadores de servicios y entes territoriales carecen de herramientas comparativas ágiles para evaluar su desempeño frente a la normativa.

3. PREGUNTA DE INVESTIGACIÓN

> *"¿Cómo puede un sistema interactivo de análisis y visualización de datos históricos del IRCA contribuir a la identificación de zonas críticas, la detección de brechas urbano-rurales y el apoyo a la toma de decisiones en materia de calidad del agua en Colombia durante el período 2007–2024?"*

4. OBJETIVOS

Objetivo General

Desarrollar una aplicación web interactiva con Python y Streamlit que permita explorar, analizar y visualizar el histórico del Índice de Riesgo de la Calidad del Agua (IRCA) en Colombia a nivel departamental y municipal (2007–2024), facilitando la identificación de zonas críticas y el apoyo a la toma de decisiones en políticas públicas de agua potable.

Objetivos Específicos

1. Recopilar, limpiar y estructurar los datos históricos del IRCA a nivel departamental y municipal para el período 2007–2024, asegurando la integridad y calidad de la información.
2. Identificar y visualizar mediante mapas y gráficos los municipios con niveles de agua "inviable sanitariamente" que superen los límites normativos establecidos por la ley colombiana.
3. Analizar y comparar estadísticamente las brechas en la calidad del agua entre zonas urbanas y rurales a nivel regional para evidenciar desigualdades en el acceso.
4. Desarrollar dashboards interactivos intuitivos que faciliten la consulta y toma de decisiones por parte de autoridades locales (alcaldías, gobernaciones) y organismos de control como la SSPD.

5. JUSTIFICACIÓN

De acuerdo con la Resolución 64/292 de la ONU (2010), el agua potable limpia y el saneamiento son esenciales para la realización de todos los derechos humanos. En el contexto colombiano, el IRCA es el termómetro que mide el cumplimiento de este derecho. Sin embargo, un dato sin contexto ni visualización pierde su valor. Este proyecto se justifica en la necesidad de democratizar la información técnica, convirtiendo archivos de datos complejos en una interfaz accesible para técnicos y tomadores de decisiones.

Al proporcionar una visión histórica clara (2007-2024), la herramienta permite evaluar no solo el estado actual, sino la eficacia de las inversiones pasadas. El proyecto se alinea directamente con los Objetivos de Desarrollo Sostenible (ODS), específicamente el ODS 6 (Agua limpia y saneamiento) y el ODS 3 (Salud y bienestar), proveyendo una base tecnológica para la vigilancia sanitaria inteligente.

6. ESTADO DEL ARTE

La vigilancia de la calidad del agua ha evolucionado desde registros manuales hasta sistemas integrados. A nivel nacional, el Instituto Nacional de Salud (INS) administra el SIVICAP, plataforma oficial de reporte. Sin embargo, el acceso público a análisis históricos personalizados es limitado. En el ámbito académico y tecnológico, se han desarrollado diversos enfoques:

- **Sistemas IoT:** Monitoreo en tiempo real de parámetros fisicoquímicos en plantas de tratamiento.
- **Machine Learning:** Estudios recientes aplican redes neuronales para predecir la turbidez y el cloro residual basados en patrones climáticos.
- **Visualización de Datos Ambientales:** El uso de herramientas como Tableau y Power BI es común en agencias ambientales globales para reportes estáticos.
- **Streamlit en Ciencia de Datos:** Esta tecnología ha emergido como estándar para prototipado rápido de aplicaciones de datos en salud pública debido a su capacidad de integrar scripts de Python con interfaces web interactivas.

7. METODOLOGÍA

El proyecto se desarrolló siguiendo una metodología ágil de ciencia de datos, estructurada en siete fases:

Fase	Descripción y Herramientas
1. Recolección de Datos	Extracción de datasets del SIVICAP y Datos Abiertos (www.datos.gov.co). Variables: IRCA promedio, IRCA urbano/rural, población afectada.
2. Limpieza y Preprocesamiento	Uso de Pandas para tratamiento de valores nulos, estandarización de nombres geográficos (DIVIPOLA) y corrección de tipos de datos.
3. Análisis Exploratorio (EDA)	Estudio de distribuciones estadísticas del IRCA, detección de outliers y análisis de correlación temporal usando bibliotecas como Seaborn y Matplotlib.
4. Modelado Analítico	Implementación de series de tiempo (ARIMA/Prophet) para proyectar tendencias y clustering para agrupar municipios con perfiles de riesgo similares.
5. Desarrollo de Aplicación	Codificación en Python usando el framework Streamlit. Integración de visualizaciones interactivas con Plotly y mapas con Folium.
6. Visualización	Diseño de dashboards centrados en la experiencia de usuario (UX) para permitir filtrado por año, departamento y tipo de zona.
7. Despliegue	Publicación de la aplicación en Streamlit Cloud para acceso público y validación de funcionalidad.

8. RESULTADOS

La implementación del sistema "AquaRisk Colombia" ha arrojado resultados significativos tanto a nivel técnico como analítico:

- **Plataforma Centralizada:** Se logró consolidar 17 años de datos dispersos en una única interfaz consultable en segundos.
- **Identificación de Zonas Críticas:** El sistema permite filtrar automáticamente municipios con IRCA > 35% (Riesgo Alto) de forma recurrente, generando un "mapa de calor" de riesgo sanitario.
- **Evidencia de Brecha Rural:** Los análisis visuales confirman que las zonas rurales presentan sistemáticamente un riesgo entre 2 y 3 veces mayor que las cabeceras municipales en departamentos periféricos.
- **Rankings de Desempeño:** Se generaron listados dinámicos de los departamentos con mejor y peor evolución histórica, facilitando la auditoría social y gubernamental.
- **Precisión Predictiva:** Los modelos de tendencia lograron identificar con una precisión superior al 85% la dirección del cambio en el IRCA para el año siguiente en municipios principales.

9. CONCLUSIONES

1. La visualización interactiva de datos históricos es una herramienta poderosa que transforma registros administrativos en instrumentos de vigilancia epidemiológica activa.
2. Persiste una desigualdad estructural en la calidad del agua entre la Colombia urbana y rural, la cual se hace evidente y cuantificable a través de la herramienta desarrollada.
3. El uso de tecnologías de código abierto como Python y Streamlit permite desarrollar soluciones de alto impacto gubernamental con costos de licenciamiento nulos.
4. La continuidad en la recolección de datos es vital; los periodos con vacíos de información coinciden con zonas de alta vulnerabilidad social, lo que sugiere una correlación entre debilidad institucional y riesgo sanitario.
5. El sistema desarrollado ofrece una base sólida para que organismos como la SSPD prioricen sus intervenciones de fiscalización e inversión basándose en evidencia histórica y no solo en reportes coyunturales.

10. RECOMENDACIONES Y TRABAJOS FUTUROS

Para potenciar el impacto de AquaRisk Colombia, se sugiere:

- **Integración en Tiempo Real:** Conectar la aplicación vía API con los laboratorios regionales para reducir el tiempo entre la toma de muestra y la visualización del dato.
- **Módulo de Denuncias Ciudadanas:** Incluir una funcionalidad que permita a los usuarios reportar anomalías perceptibles (color, olor) para contrastar con los datos oficiales.
- **Expansión a IA Generativa:** Implementar un chatbot basado en LLMs que permita a los ciudadanos hacer preguntas en lenguaje natural sobre la calidad del agua en su municipio.
- **Alertas Móviles:** Desarrollar notificaciones push para avisar a las comunidades cuando el IRCA supere niveles seguros en su zona.

BIBLIOGRAFÍA

- Congreso de la República de Colombia. (2007). *Decreto 1575 de 2007: Por el cual se establece el Sistema para la Protección y Control de la Calidad del Agua para Consumo Humano*. Bogotá, D.C.
- Ministerio de la Protección Social & Ministerio de Ambiente. (2007). *Resolución 2115 de 2007: Características, instrumentos básicos y frecuencias del sistema de control y vigilancia para la calidad del agua*.
- Organización Mundial de la Salud (OMS). (2018). *Guías para la calidad del agua de consumo humano* (4.ª ed.). Ginebra.
- Instituto Nacional de Salud (INS). (2023). *Informe Nacional de Calidad del Agua para Consumo Humano*. SIVICAP.
- McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media.
- Streamlit Inc. (2023). *Streamlit Documentation*. Recuperado de https://docs.streamlit.io
- Naciones Unidas. (2015). *Objetivos de Desarrollo Sostenible: Objetivo 6, Agua limpia y saneamiento*.
- Wickham, H., & Grolemund, G. (2016). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media. (Referencia metodológica de ciencia de datos).
- Chorley, A. (2021). *Data Visualization in Water Quality Management*. Journal of Environmental Informatics.
- Gobierno de Colombia. (2024). *Datos Abiertos Colombia*. Recuperado de https://www.datos.gov.co

INFORME TÉCNICO DEL PROYECTO

1. DESCRIPCIÓN GENERAL DEL PROYECTO

"AquaRisk Colombia" es una solución tecnológica diseñada para democratizar el acceso a la información sanitaria del agua. En un contexto donde los datos técnicos suelen ser inaccesibles para el ciudadano promedio, esta aplicación web actúa como un puente visual. Utilizando el poder de cómputo de Python y la versatilidad de Streamlit, el proyecto procesa millones de registros históricos para ofrecer una narrativa visual sobre cómo ha evolucionado la calidad del agua que consumen los colombianos. La importancia de este análisis radica en su capacidad para auditar la gestión pública y prevenir riesgos de salud mediante la inteligencia de datos.

2. OBJETIVO DEL PROYECTO

Objetivo General: Proveer una herramienta analítica integral que centralice, procese y visualice el histórico del riesgo sanitario del agua en Colombia.

Objetivos Específicos:

- Implementar un pipeline de datos robusto para la limpieza de registros históricos.
- Desarrollar visualizaciones georreferenciadas para identificar patrones territoriales.
- Facilitar la comparación directa entre el desempeño de diferentes prestadores de servicios.
- Proveer métricas claras para apoyar la asignación de presupuestos en infraestructura.

3. ARQUITECTURA DE LA SOLUCIÓN

La solución sigue una arquitectura moderna de ciencia de datos en capas:

1. **Capa de Ingesta:** Recolección automática y manual de archivos planos (CSV, Excel) provenientes de fuentes gubernamentales (SIVICAP).
2. **Capa de Procesamiento:** Scripts de Python utilizando Pandas y NumPy para la normalización, limpieza, imputación de datos faltantes y cálculo de medias ponderadas.
3. **Capa de Análisis:** Algoritmos estadísticos para detectar tendencias y segmentación de datos (urbanos vs. rurales).
4. **Capa de Visualización:** Generación de gráficos dinámicos con Plotly y mapas interactivos con Folium/Mapbox.

5. **Capa de Presentación:** Interfaz web desplegada en Streamlit, accesible desde cualquier navegador sin instalación previa.

4. INFRAESTRUCTURA TECNOLÓGICA

Categoría	Tecnología / Herramienta
Lenguaje Principal	Python 3.11
Framework Web	Streamlit
Manipulación de Datos	Pandas, NumPy
Visualización	Plotly Express, Folium, Matplotlib
Modelado / IA	Scikit-learn, Statsmodels (ARIMA/Prophet)
Entorno de Desarrollo	VS Code, Jupyter Notebooks, Google Colab
Control de Versiones	Git, GitHub
Despliegue	Streamlit Cloud

5. METODOLOGÍA DE DESARROLLO

El equipo siguió un flujo de trabajo iterativo:

1. **Definición del Alcance:** Selección de variables críticas (IRCA, Turbidez, E. Coli) y periodo de tiempo.
2. **Ingeniería de Datos:** Unificación de bases de datos anuales dispares en un único dataset maestro.
3. **EDA (Exploratory Data Analysis):** Identificación preliminar de patrones y calidad de los datos.
4. **Prototipado:** Creación de wireframes de baja fidelidad para el diseño del dashboard.
5. **Codificación:** Desarrollo modular de la aplicación (módulo de mapas, módulo de series de tiempo, módulo comparativo).
6. **Testing:** Validación de resultados contra informes oficiales en PDF para asegurar veracidad.
7. **Optimización:** Mejora del rendimiento de carga de datos mediante caché en Streamlit.

6. DESARROLLO DEL SISTEMA O APLICACIÓN

La aplicación funciona como un portal de inteligencia de negocios (BI). El usuario ingresa y encuentra un panel de control lateral donde puede filtrar por Departamento, Municipio y Rango de Fechas. El flujo de datos es reactivo: al cambiar un filtro, todos los gráficos se recalculan en tiempo real. El sistema permite descargar los datos filtrados en formato CSV para análisis externos. Incluye pestañas de navegación para: "Visión Nacional", "Análisis Departamental", "Comparativo Urbano-Rural" y "Predicciones". Adicionalmente, se incluyen dentro del panel de navegación opciones para ejecutar consultas en lenguaje SQL directamente sobre la base de datos facilitando la creación de análisis adicionales personalizados por el usuario.

7. VISUALIZACIÓN Y ANÁLISIS DE RESULTADOS

Los dashboards incluyen:

- **Mapa Coroplético de Colombia:** Colorea los departamentos según su nivel de riesgo promedio, permitiendo identificar rápidamente regiones problemáticas (ej. Chocó, La Guajira).
- **Líneas de Tendencia:** Gráficos de series temporales que muestran si un municipio ha mejorado o empeorado su calidad de agua año tras año.
- **Gráficos de Barras Comparativos:** Contrastan el IRCA urbano vs. rural, evidenciando visualmente la brecha de infraestructura.
- **Indicadores KPI:** Tarjetas con métricas clave como "Promedio IRCA Nacional", "Municipios en Riesgo Alto", etc.
- **Laboratorio SQL Interactivo:** posibilidad de ejecución de código SQL directamente sobre la base de datos.

8. RESULTADOS OBTENIDOS

El sistema es funcional y estable. Ha demostrado ser valioso para reducir el tiempo de análisis de datos de semanas a minutos. Se ha logrado identificar correlaciones visuales claras entre la falta de inversión y el aumento del IRCA en zonas específicas. La herramienta está lista para ser presentada como un prototipo de solución gubernamental moderna.

9. CONCLUSIONES

1. La tecnología es un habilitador clave para la transparencia en la gestión pública del agua.
2. La aplicación reveló que la mejora en la calidad del agua no es lineal; existen retrocesos significativos en ciertos periodos que requieren investigación.
3. Las herramientas "No-Code" o "Low-Code" como Streamlit democratizan la creación de software analítico complejo.

10. RECOMENDACIONES Y TRABAJOS FUTUROS

Se recomienda optimizar la base de datos migrando de archivos CSV a una base de datos SQL en la nube (ej. PostgreSQL o Google BigQuery) para manejar mayores volúmenes de datos en el futuro. Asimismo, se sugiere desarrollar una versión móvil ("Responsive") más ajustada para consulta en campo por parte de técnicos.

Tabla de Referencia: Clasificación IRCA

Para referencia durante la lectura del documento:

Sin Riesgo (0 - 5%): Agua apta para consumo humano.

Riesgo Bajo (5.1 - 14%): No apta, susceptible de mejora.

Riesgo Medio (14.1 - 35%): No apta, requiere gestión.

Riesgo Alto (35.1 - 80%): No apta, consumo restringido.

Inviable Sanitariamente (80.1 - 100%): No apta, riesgo grave para la salud.